

# Cómo funciona la tecnología y cuáles son sus límites

Agente GPT · Appraisal Checklist de PRODOCs

---

**Expositor:** Ahmed Eid

**Sesión:** Día 1 · jueves 27 de agosto de 2026 · 9:30–10:30 (Lima)

**Bloque:** Punto 4 · 30 minutos + preguntas integradas

# Qué vamos a cubrir

- 1 De dónde viene** de la aplicación Streamlit al Agente GPT
- 2 Cómo está construido** la rúbrica, los tests, la búsqueda de evidencia
- 3 Por qué repite** aleatoriedad, 10 corridas y estabilidad
- 4 Qué NO hace** límites reales y comparación con el GPT Empresarial
- 5 Demostración** cargar → ejecutar → interpretar el Excel

**Las preguntas se integran a este bloque:** interrúmpanme en cualquier momento.

# De dónde viene: de Streamlit al Agente GPT

|                     | Aplicación Streamlit               | Agente GPT                       |
|---------------------|------------------------------------|----------------------------------|
| <b>Acceso</b>       | URL + contraseña de entorno        | Enlace de ChatGPT                |
| <b>Instalación</b>  | Servidor propio, dependencias      | Ninguna: se abre en el navegador |
| <b>Curva de uso</b> | Interfaz con pestañas y parámetros | Conversación en lenguaje natural |
| <b>Rúbrica</b>      | Cargada en el servidor             | Cargada en el servidor (igual)   |
| <b>Motor</b>        | El mismo código de evaluación      | El mismo código de evaluación    |
| <b>Salida</b>       | Excel descargable                  | Excel descargable (igual)        |

**El motor no cambió.** Cambió la puerta de entrada: el Agente elimina la barrera de instalación y de interfaz.

# Qué es un GPT, en términos sencillos

- **Un modelo de lenguaje predice texto.** Ha leído enormes cantidades de texto y aprendió qué palabras siguen a otras en un contexto dado.
- **No es una base de datos.** No «consulta» el PRODOC como quien busca en un archivo: lo lee completo y razona sobre él en ese momento.
- **No es un buscador.** No hay una lista de respuestas correctas guardada en algún lugar que el sistema recupere.
- **Es un lector que sigue instrucciones.** Le entregamos el documento, la rúbrica y una instrucción muy precisa, y devuelve un juicio con la cita que lo sustenta.

**Consecuencia práctica:** el Agente solo puede ver lo que está escrito en el PRODOC. Lo que el especialista sabe y no documentó, no existe para él.

# Lo que el Agente no hace

| No hace esto                     | Por qué                                      | Qué implica para usted                                |
|----------------------------------|----------------------------------------------|-------------------------------------------------------|
| Aprobar o rechazar un PRODOC     | No emite determinaciones oficiales de la OIT | La decisión sigue siendo del appraiser                |
| Adivinar lo no documentado       | Solo lee el texto entregado                  | Un «No» puede ser una brecha documental, no de diseño |
| Recordar evaluaciones anteriores | Cada corrida parte de cero                   | No compara automáticamente entre proyectos            |
| Redactar el PRODOC corregido     | No es su propósito ni su alcance             | Le señala dónde mirar, no qué escribir                |
| Dar siempre la misma respuesta   | Hay aleatoriedad inherente                   | Por eso repetimos y medimos estabilidad               |

**Diseño deliberado:** preferimos un diagnóstico acotado y auditable antes que una recomendación amplia sin respaldo en el documento.

# Cómo se incorporó el Appraisal Checklist

**1** **Se digitalizó la rúbrica** cada criterio pasó a una fila estructurada, no a un texto libre

**2** **Se descompuso en tests** cada criterio se expresa como preguntas booleanas T1, T2, T3...

**3** **Se escribió la regla de decisión** una fórmula explícita determina Yes / Partial / No

**4** **Se fijaron anclas verificables** términos y expresiones que el Agente debe buscar en el texto

**5** **Se marcó la subjetividad** cada criterio se etiqueta Alta / Media / Baja

**La rúbrica vive en el servidor.** El usuario nunca la sube: se evalúa siempre contra la misma versión institucional.

# Qué evalúa: 76 criterios en 5 secciones

| Sección | Contenido                 | Criterios | Subsecciones |
|---------|---------------------------|-----------|--------------|
| 1       | Pertinencia               | 20        | 1.1 – 1.5    |
| 2       | Validez del diseño        | 13        | 2.1 – 2.4    |
| 3       | Marco de resultados y R&M | 27        | 3.1 – 3.7    |
| 4       | Implementación            | 14        | 4.1 – 4.4    |
| 5       | Presentación              | 2         | 5.1 – 5.2    |

**Se puede filtrar:** rúbrica completa, una sección («solo la sección 3») o subsecciones concretas («solo 1.1 y 2.3»). Filtrar reduce tiempo y costo.

# De criterio a tests: cómo «entiende» un criterio

El criterio no se evalúa como una impresión general.

Se descompone en preguntas cerradas que se responden una por una, con evidencia citada:

| Test | Pregunta cerrada                                                             | Respuesta |
|------|------------------------------------------------------------------------------|-----------|
| T1   | ¿Distingue el tipo de enfoque (sensible / responsivo / transformador)?       | sí / no   |
| T2   | ¿Articula cómo el proyecto cuestiona normas o relaciones de poder?           | sí / no   |
| T3   | ¿Hay acciones dedicadas a transformar relaciones, no solo a incluir mujeres? | sí / no   |

**DECISIÓN:**  $T1 \wedge T2 \wedge T3 \rightarrow \text{Yes}$     •     $T1 \vee T3$  (sin cumplir los tres)  
 $\rightarrow \text{Partial}$     •     $\neg T1 \wedge \neg T3 \rightarrow \text{No}$

**Esto es lo que hace auditable el resultado:** usted puede revisar test por test dónde y por qué el Agente llegó a esa conclusión.

# Cómo busca evidencia: DEDICADO vs MARCO

No basta con que una palabra aparezca en el documento. El Agente clasifica cada mención antes de contarla como evidencia.

|          | MARCO (no cuenta)                                                                        | DEDICADO (sí cuenta)                                                                                                          |
|----------|------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| Qué es   | El tema aparece mencionado, sin desarrollo propio                                        | El tema tiene un espacio propio en el diseño                                                                                  |
| Ejemplos | Listas de $\geq 3$ grupos • lenguaje de inclusión genérico • enumeraciones «entre otros» | Producto o resultado que lo nombra • indicador desagregado • actividad dedicada • partida presupuestaria • meta cuantificable |

**Regla dura:** si toda la evidencia citable es MARCO, el resultado debe ser «No» o «Not Found», sin importar cuántas veces se nombre el tema.

# Por qué cada criterio se evalúa 10 veces

- **Un modelo de lenguaje no es determinista.** La misma pregunta sobre el mismo documento puede producir respuestas distintas.
- **Preguntar una sola vez sería frágil.** Estaríamos entregando el resultado de un único lanzamiento.
- **Solución: repetir y consolidar.** Cada criterio se evalúa 10 veces de forma independiente y se toma el resultado más frecuente (la moda).
- **El desacuerdo es información, no ruido.** Cuántas de las 10 corridas coincidieron es un dato que se reporta y que usted debe leer.

**Una valoración completa** son  $76 \text{ criterios} \times 10 \text{ corridas} \approx 760 \text{ consultas al modelo}$ . Por eso tarda y por eso conviene filtrar por sección.

# De dónde procede la aleatoriedad

| Fuente                    | Qué ocurre                                                                 | Cómo lo controlamos                               |
|---------------------------|----------------------------------------------------------------------------|---------------------------------------------------|
| Generación probabilística | El modelo elige entre continuaciones posibles; no siempre la misma         | 10 corridas + resultado modal                     |
| Criterios ambiguos        | Cuando la rúbrica admite lectura, el modelo puede inclinarse distinto      | Tests cerrados y reglas de decisión explícitas    |
| Evidencia dispersa        | Si la evidencia está repartida, distintas corridas citan pasajes distintos | Filtro DEDICADO / MARCO                           |
| Documentos extensos       | Más texto, más margen de lectura parcial                                   | Extracción estructurada y evaluación por criterio |

**No se elimina la aleatoriedad: se mide y se reporta.** Eso es preferible a ocultarla detrás de una respuesta única.

# Qué significa «estabilidad»

**Estabilidad (%)** = de las 10 corridas, cuántas coincidieron con el resultado final.

Umbral institucional: **80%**. Por debajo, el criterio se marca para revisión humana.

| Estabilidad | Lectura                        | Qué hacer                                                        |
|-------------|--------------------------------|------------------------------------------------------------------|
| 100 – 80%   | El modelo fue consistente      | Tratar como diagnóstico sólido; verificar la evidencia           |
| 79 – 50%    | Hubo desacuerdo entre corridas | Revisión humana obligatoria; leer el Resultado Alternativo       |
| < 50%       | No hubo consenso real          | El criterio es ambiguo o la evidencia insuficiente: decida usted |

**La estabilidad no mide si el Agente acertó.** Mide cuánta confianza interna tuvo. Un 100% equivocado es posible: por eso siempre se verifica la evidencia.

# Criterios subjetivos y revisión humana

- Cada criterio trae una etiqueta de subjetividad: **Alta • Media • Baja**.
- **Alta subjetividad** = el juicio depende del contexto institucional, no solo del texto. Ejemplo: si un enfoque de género es «transformador».
- **Estos criterios reciben más razonamiento** del modelo y se marcan automáticamente en la columna «Revisión humana recomendada».
- **Dos disparadores de esa marca:** subjetividad alta, o estabilidad por debajo de 80%.

**Úsela como cola de trabajo:** empiece por los criterios marcados. Ahí es donde su juicio profesional aporta más valor.

# Ventajas y desventajas de esta tecnología

|                     | Ventaja                                                  | Desventaja / costo                             |
|---------------------|----------------------------------------------------------|------------------------------------------------|
| <b>Cobertura</b>    | Revisa los 76 criterios sin fatiga ni sesgo de cansancio | Revisa lo escrito, no lo sabido                |
| <b>Tiempo</b>       | Libera horas del especialista para atender brechas       | Una corrida completa tarda varios minutos      |
| <b>Trazabilidad</b> | Cita la evidencia y muestra el razonamiento por test     | Genera mucho detalle: exige saber leerlo       |
| <b>Consistencia</b> | Aplica la misma rúbrica a todos los proyectos            | No es determinista: por eso repetimos          |
| <b>Costo</b>        | Bajo por documento frente al tiempo humano equivalente   | Se paga por consulta: el presupuesto es finito |

**Tokens y presupuesto:** el costo depende del tamaño del PRODOC y de cuántos criterios se evalúen.  
Filtrar por sección es la palanca directa de ahorro.

# ¿Y si uso el GPT Empresarial de la OIT?

|             | GPT Empresarial                                          | Agente Appraisal Checklist                           |
|-------------|----------------------------------------------------------|------------------------------------------------------|
| Rúbrica     | Habría que subirla en cada conversación                  | Cargada en el servidor, versión única                |
| Aplicación  | Lectura general del archivo adjunto                      | Cada criterio se ejecuta por separado, con sus tests |
| Repetición  | Una sola pasada                                          | 10 corridas por criterio + resultado modal           |
| Estabilidad | No disponible                                            | Reportada por criterio, con umbral de 80%            |
| Salida      | Texto en la conversación                                 | Excel estructurado, auditable y archivable           |
| Acceso hoy  | <b>Sin acceso al Agente desde el entorno empresarial</b> | Enlace de ChatGPT                                    |

**El valor agregado no es «usar IA»:** es la rúbrica institucional aplicada criterio por criterio, repetida y medida. Eso el GPT genérico no lo reproduce.

# Los tres límites que hay que tener presentes

1

**Es una primera revisión completa,** no un diagnóstico determinista. Señala brechas para que usted las examine.

2

**Trabaja sobre la evidencia del documento,** no sobre el proyecto real ni sobre lo que usted sabe de él.

3

**No sustituye el juicio del appraiser.** El resultado es un insumo; la determinación sigue siendo humana.

**Ninguna salida constituye una determinación oficial de la OIT.** Es una valoración asistida que requiere validación experta.

---

## Parte 2 • La herramienta en uso

Cargar → seleccionar → ejecutar → descargar → interpretar

# El flujo completo, en cinco pasos

- 1** **Cargar el PRODOC** un único archivo .docx por evaluación
- 2** **Seleccionar el alcance** rúbrica completa, una sección o subsecciones concretas
- 3** **Ejecutar** el Agente lanza el trabajo y consulta su avance hasta terminar
- 4** **Descargar el Excel** es el registro auditable de la evaluación
- 5** **Interpretar** localizar evidencia y priorizar los criterios marcados

**Indique el alcance en el mismo mensaje en que sube el archivo:** ahorra una ronda de preguntas y acota el costo desde el inicio.

# Pasos 1 y 2 • Cargar y acotar

- **Abra el Agente y salude.** Se presenta solo: explica qué evalúa, qué secciones existen y qué puede filtrar. Eso no consume una evaluación.
- **Adjunte un solo .docx.** Si sube varios, el Agente le pedirá elegir uno: la evaluación es de un documento por vez.
- **Diga qué quiere evaluar.** Ejemplos de instrucción:
  - «Evalúa este PRODOC con la rúbrica completa»
  - «Evalúa solo la sección 3 (Marco de resultados) y resume las brechas»
  - «Evalúa solo 1.1 y 2.3»

**Recomendación para empezar:** una sección primero. Llega antes, cuesta menos y permite calibrar la lectura antes de una corrida completa.

# Paso 3 • Qué ocurre mientras se ejecuta

- 1** El Agente descarga el documento y extrae su texto por secciones
- 2** Carga la rúbrica del servidor y filtra los criterios que usted pidió
- 3** Lanza las evaluaciones en paralelo cada criterio, 10 veces, hasta 48 consultas simultáneas
- 4** Consolida cada criterio resultado modal + porcentaje de estabilidad
- 5** Construye el Excel y lo entrega en la conversación

Si es la primera evaluación del día puede tardar más en arrancar: el servicio se suspende por inactividad y necesita unos segundos para despertar. Es esperado.

# Paso 4 • El Excel: hoja «Resultado Diagnóstico»

Una sola hoja, con una fila por criterio evaluado. Es el registro auditable: consérvelo.

| Grupo de columnas | Qué contiene                                                      | Para qué sirve                          |
|-------------------|-------------------------------------------------------------------|-----------------------------------------|
| Identificación    | ID • Subsección • Criterio • Transversales                        | Ubicar el criterio en el Checklist      |
| Resultado         | Respuesta (Yes / Partial / No / Not Found / N/A)                  | El diagnóstico del criterio             |
| Confianza         | Estabilidad (%) • Estable ( $\geq 80\%$ ) • Resultado Alternativo | Cuánto coincidieron las 10 corridas     |
| Sustento          | Razonamiento (test por test) • Evidencia citada                   | Verificar por qué llegó a ese resultado |
| Prioridad         | <b>Revisión humana recomendada</b>                                | Su cola de trabajo                      |

«Not Found» no es «No». «No» afirma que el criterio no se cumple; «Not Found» afirma que el documento no permite determinarlo. La acción es distinta.

# Cómo leer una fila, en orden

1

**Mire la Respuesta** Yes / Partial / No / Not Found / N/A

2

**Mire la Estabilidad** ¿coincidieron las 10 corridas o hubo desacuerdo?

3

**Lea la Evidencia citada** ¿ese pasaje realmente sostiene el resultado?

4

**Lea el Razonamiento** test por test: dónde exactamente falló el criterio

5

**Decida** ¿brecha de diseño, brecha documental, o error del Agente?

**Nunca acepte una respuesta sin abrir la evidencia.** La evidencia es lo que convierte un resultado automático en un diagnóstico defendible.

# Paso 5 • Localizar la evidencia en el PRODOC

- **La columna Evidencia trae la cita textual** que el Agente usó. Búsquela en el PRODOC con Ctrl+F para verla en su contexto.
- **Cuando la evidencia es una ausencia**, el Agente lo dice explícitamente: «No se encontró sección X». Eso también es un hallazgo verificable.
- **Tres desenlaces posibles al verificar:**

**La información sí está y el Agente no la reconoció** → se descarta el diagnóstico automático

**La información no está pero el formulador la conoce** → mejorar el PRODOC

**La información no existe aún** → resolver antes de cerrar la formulación, o trasladar a inception

**La fórmula:** ¿existe? → ¿es suficiente? → ¿está documentado?

# Vinculación con otros recursos

| Recurso                  | Qué aporta                                                                       | Ejemplo de uso                                                                                          |
|--------------------------|----------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------|
| Chatea con el Agente     | Preguntar sobre el resultado ya generado, en lenguaje natural                    | «Resume las brechas de la sección 3 en tres puntos»                                                     |
| Otros GPTs desarrollados | Atributos Específicos (género, participación, transición justa) y Sostenibilidad | Profundizar un tema que el Checklist solo toca de forma transversal                                     |
| Chatbot i-EVal           | Evidencia de evaluaciones anteriores en la región                                | «¿Qué problemas recurrentes han identificado las evaluaciones en proyectos con ministerios de trabajo?» |

**El Excel no es el final del proceso:** es el punto de partida de la conversación con el equipo formulador.

# Preguntas frecuentes

| Pregunta                                        | Respuesta breve                                                                              |
|-------------------------------------------------|----------------------------------------------------------------------------------------------|
| ¿Por qué puede cambiar una respuesta?           | El modelo no es determinista. Por eso repetimos 10 veces y reportamos estabilidad.           |
| ¿Qué significa una estabilidad de 50–70%?       | Las corridas no coincidieron: criterio ambiguo o evidencia insuficiente. Revisión humana.    |
| ¿Por qué no encontró algo que yo sé que existe? | Solo lee el documento. Si está y no lo vio, verifíquelo y descarte el diagnóstico.           |
| ¿Por qué no me da recomendaciones de mejora?    | No incorpora conocimiento externo al documento. Las recomendaciones salen de su lectura.     |
| ¿Cuánto cuesta evaluar un PRODOC?               | Depende del tamaño del documento y de cuántos criterios se evalúen. Filtrar reduce el costo. |
| ¿Puedo evaluar otros documentos?                | Para género, participación, transición justa y sostenibilidad existen agentes específicos.   |

# Qué recordar de este bloque

- **El Agente lee el documento, no el proyecto.** Un «No» puede ser una brecha de diseño o simplemente algo no documentado. Distinguirlo es trabajo suyo.
- **Repite 10 veces y le dice cuánto coincidió.** La estabilidad es una medida de confianza interna, no de acierto.
- **Todo resultado viene con su evidencia.** Verifíquela siempre: es lo que hace el diagnóstico defendible ante el equipo formulador.
- **La columna «Revisión humana recomendada» es su cola de trabajo.** Empiece por ahí.

**El valor de la herramienta depende de la calidad de la revisión humana posterior.**

---

# Preguntas

Agente GPT · Appraisal Checklist de PRODOCs · Ahmed Eid