

Cómo funciona la tecnología y cuáles son sus límites

Agente GPT · Appraisal Checklist de PRODOCs

Expositor: Ahmed Eid

Sesión: Día 1 · jueves 27 de agosto de 2026 · 9:30–10:30 (Lima)

Bloque: Punto 4 · 30 minutos + preguntas integradas

Qué vamos a cubrir

- 1 De dónde viene** de la aplicación Streamlit al Agente GPT
- 2 Cómo está construido** la rúbrica, los tests, la búsqueda de evidencia
- 3 Por qué repite** aleatoriedad, 10 corridas y estabilidad
- 4 Qué NO hace** límites reales y comparación con el GPT Empresarial
- 5 Demostración** cargar → ejecutar → interpretar el Excel

Las preguntas se integran a este bloque: interrúmpanme en cualquier momento.

De dónde viene: de Streamlit al Agente GPT

	Aplicación Streamlit	Agente GPT
Acceso	URL + contraseña de entorno	Enlace de ChatGPT
Instalación	Servidor propio, dependencias	Ninguna: se abre en el navegador
Curva de uso	Interfaz con pestañas y parámetros	Conversación en lenguaje natural
Rúbrica	Cargada en el servidor	Cargada en el servidor (igual)
Motor	El mismo código de evaluación	El mismo código de evaluación
Salida	Excel descargable	Excel descargable (igual)

El motor no cambió. Cambió la puerta de entrada: el Agente elimina la barrera de instalación y de interfaz.

Qué es un GPT, en términos sencillos

- **Un modelo de lenguaje predice texto.** Ha leído enormes cantidades de texto y aprendió qué palabras siguen a otras en un contexto dado.
- **No es una base de datos.** No «consulta» el PRODOC como quien busca en un archivo: lo lee completo y razona sobre él en ese momento.
- **No es un buscador.** No hay una lista de respuestas correctas guardada en algún lugar que el sistema recupere.
- **Es un lector que sigue instrucciones.** Le entregamos el documento, la rúbrica y una instrucción muy precisa, y devuelve un juicio con la cita que lo sustenta.

Consecuencia práctica: el Agente solo puede ver lo que está escrito en el PRODOC. Lo que el especialista sabe y no documentó, no existe para él.

Lo que el Agente no hace

No hace esto	Por qué	Qué implica para usted
Aprobar o rechazar un PRODOC	No emite determinaciones oficiales de la OIT	La decisión sigue siendo del appraiser
Adivinar lo no documentado	Solo lee el texto entregado	Un «No» puede ser una brecha documental, no de diseño
Recordar evaluaciones anteriores	Cada corrida parte de cero	No compara automáticamente entre proyectos
Redactar el PRODOC corregido	No es su propósito ni su alcance	Le señala dónde mirar, no qué escribir
Dar siempre la misma respuesta	Hay aleatoriedad inherente	Por eso repetimos y medimos estabilidad

Diseño deliberado: preferimos un diagnóstico acotado y auditable antes que una recomendación amplia sin respaldo en el documento.

Cómo se incorporó el Appraisal Checklist

1 **Se digitalizó la rúbrica** cada criterio pasó a una fila estructurada, no a un texto libre

2 **Se descompuso en tests** cada criterio se expresa como preguntas booleanas T1, T2, T3...

3 **Se escribió la regla de decisión** una fórmula explícita determina Yes / Partial / No

4 **Se fijaron anclas verificables** términos y expresiones que el Agente debe buscar en el texto

5 **Se marcó la subjetividad** cada criterio se etiqueta Alta / Media / Baja

La rúbrica vive en el servidor. El usuario nunca la sube: se evalúa siempre contra la misma versión institucional.

Qué evalúa: 76 criterios en 5 secciones

Sección	Contenido	Criterios	Subsecciones
1	Pertinencia	20	1.1 – 1.5
2	Validez del diseño	13	2.1 – 2.4
3	Marco de resultados y R&M	27	3.1 – 3.7
4	Implementación	14	4.1 – 4.4
5	Presentación	2	5.1 – 5.2

Se puede filtrar: rúbrica completa, una sección («solo la sección 3») o subsecciones concretas («solo 1.1 y 2.3»). Filtrar reduce tiempo y costo.

De criterio a tests: cómo «entiende» un criterio

El criterio no se evalúa como una impresión general.

Se descompone en preguntas cerradas que se responden una por una, con evidencia citada:

Test	Pregunta cerrada	Respuesta
T1	¿Distingue el tipo de enfoque (sensible / responsivo / transformador)?	sí / no
T2	¿Articula cómo el proyecto cuestiona normas o relaciones de poder?	sí / no
T3	¿Hay acciones dedicadas a transformar relaciones, no solo a incluir mujeres?	sí / no

DECISIÓN: $T1 \wedge T2 \wedge T3 \rightarrow \text{Yes}$ • $T1 \vee T3$ (sin cumplir los tres)
 $\rightarrow \text{Partial}$ • $\neg T1 \wedge \neg T3 \rightarrow \text{No}$

Esto es lo que hace auditable el resultado: usted puede revisar test por test dónde y por qué el Agente llegó a esa conclusión.

Cómo busca evidencia: DEDICADO vs MARCO

No basta con que una palabra aparezca en el documento. El Agente clasifica cada mención antes de contarla como evidencia.

	MARCO (no cuenta)	DEDICADO (sí cuenta)
Qué es	El tema aparece mencionado, sin desarrollo propio	El tema tiene un espacio propio en el diseño
Ejemplos	Listas de ≥ 3 grupos • lenguaje de inclusión genérico • enumeraciones «entre otros»	Producto o resultado que lo nombra • indicador desagregado • actividad dedicada • partida presupuestaria • meta cuantificable

Regla dura: si toda la evidencia citable es MARCO, el resultado debe ser «No» o «Not Found», sin importar cuántas veces se nombre el tema.

Un caso completo: del texto del PRODOC al veredicto

LO QUE DICE EL PRODOC

§ 2.3 Enfoque de género

«El proyecto adopta un enfoque de género transformador, distinguiéndolo de los enfoques meramente sensibles o responsivos.»

§ 3.1 Beneficiarios

«Se priorizará la participación de mujeres, jóvenes, personas con discapacidad y pueblos indígenas.»

§ 4.2 Actividad 2.4

«Mesas de trabajo con cooperativas para revisar los criterios de acceso al crédito que excluyen a las mujeres titulares. Presupuesto: USD 18.000.»

CÓMO LO EVALÚA EL AGENTE

✓ **T1 • Distingue el tipo de enfoque**
§ 2.3 nombra y distingue los tres enfoques.

✗ **T2 • Articula cómo cuestiona normas de poder**
declara el enfoque, pero no explica el mecanismo en ninguna sección.

✓ **T3 • Acciones dedicadas a transformar relaciones**
§ 4.2 revisa reglas de acceso al crédito, con presupuesto propio.

§ 3.1 no cuenta como evidencia
- lista de cuatro grupos sin seguimiento: es MARCO, no DEDICADO.

DECISIÓN: se requieren $T1 \wedge T2 \wedge T3$. Se cumplen T1 y T3, falta T2 → **PARTIAL** • extracto ilustrativo, no es un PRODOC real.

Por qué cada criterio se evalúa 10 veces

- **Un modelo de lenguaje no es determinista.** La misma pregunta sobre el mismo documento puede producir respuestas distintas.
- **Preguntar una sola vez sería frágil.** Estaríamos entregando el resultado de un único lanzamiento.
- **Solución: repetir y consolidar.** Cada criterio se evalúa 10 veces de forma independiente y se toma el resultado más frecuente (la moda).
- **El desacuerdo es información, no ruido.** Cuántas de las 10 corridas coincidieron es un dato que se reporta y que usted debe leer.

Una valoración completa son $76 \text{ criterios} \times 10 \text{ corridas} \approx 760 \text{ consultas al modelo}$. Por eso tarda y por eso conviene filtrar por sección.

De dónde procede la aleatoriedad

Fuente	Qué ocurre	Cómo lo controlamos
Generación probabilística	El modelo elige entre continuaciones posibles; no siempre la misma	10 corridas + resultado modal
Criterios ambiguos	Cuando la rúbrica admite lectura, el modelo puede inclinarse distinto	Tests cerrados y reglas de decisión explícitas
Evidencia dispersa	Si la evidencia está repartida, distintas corridas citan pasajes distintos	Filtro DEDICADO / MARCO
Documentos extensos	Más texto, más margen de lectura parcial	Extracción estructurada y evaluación por criterio

No se elimina la aleatoriedad: se mide y se reporta. Eso es preferible a ocultarla detrás de una respuesta única.

Qué significa «estabilidad»

Estabilidad (%) = de las 10 corridas, cuántas coincidieron con el resultado final.

Umbral institucional: **80%**. Por debajo, el criterio se marca para revisión humana.

Estabilidad	Lectura	Qué hacer
100 – 80%	El modelo fue consistente	Tratar como diagnóstico sólido; verificar la evidencia
79 – 50%	Hubo desacuerdo entre corridas	Revisión humana obligatoria; leer el Resultado Alternativo
< 50%	No hubo consenso real	El criterio es ambiguo o la evidencia insuficiente: decida usted

La estabilidad no mide si el Agente acertó. Mide cuánta confianza interna tuvo. Un 100% equivocado es posible: por eso siempre se verifica la evidencia.

Criterios subjetivos y revisión humana

- Cada criterio trae una etiqueta de subjetividad: **Alta • Media • Baja**.
- **Alta subjetividad** = el juicio depende del contexto institucional, no solo del texto. Ejemplo: si un enfoque de género es «transformador».
- **Estos criterios reciben más razonamiento** del modelo y se marcan automáticamente en la columna «Revisión humana recomendada».
- **Dos disparadores de esa marca:** subjetividad alta, o estabilidad por debajo de 80%.

Úsela como cola de trabajo: empiece por los criterios marcados. Ahí es donde su juicio profesional aporta más valor.

Ventajas y desventajas de esta tecnología

	Ventaja	Desventaja / costo
Cobertura	Revisa los 76 criterios sin fatiga ni sesgo de cansancio	Revisa lo escrito, no lo sabido
Tiempo	Libera horas del especialista para atender brechas	Una corrida completa tarda varios minutos
Trazabilidad	Cita la evidencia y muestra el razonamiento por test	Genera mucho detalle: exige saber leerlo
Consistencia	Aplica la misma rúbrica a todos los proyectos	No es determinista: por eso repetimos
Costo	Bajo por documento frente al tiempo humano equivalente	Se paga por consulta: el presupuesto es finito

Tokens y presupuesto: el costo depende del tamaño del PRODOC y de cuántos criterios se evalúen.
Filtrar por sección es la palanca directa de ahorro.

¿Y si uso el GPT Empresarial de la OIT?

	GPT Empresarial	Agente Appraisal Checklist
Rúbrica	Habría que subirla en cada conversación	Cargada en el servidor, versión única
Aplicación	Lectura general del archivo adjunto	Cada criterio se ejecuta por separado, con sus tests
Repetición	Una sola pasada	10 corridas por criterio + resultado modal
Estabilidad	No disponible	Reportada por criterio, con umbral de 80%
Salida	Texto en la conversación	Excel estructurado, auditable y archivable
Acceso hoy	Sin acceso al Agente desde el entorno empresarial	Enlace de ChatGPT

El valor agregado no es «usar IA»: es la rúbrica institucional aplicada criterio por criterio, repetida y medida. Eso el GPT genérico no lo reproduce.

Los tres límites que hay que tener presentes

1

Es una primera revisión completa, no un diagnóstico determinista. Señala brechas para que usted las examine.

2

Trabaja sobre la evidencia del documento, no sobre el proyecto real ni sobre lo que usted sabe de él.

3

No sustituye el juicio del appraiser. El resultado es un insumo; la determinación sigue siendo humana.

Ninguna salida constituye una determinación oficial de la OIT. Es una valoración asistida que requiere validación experta.

Parte 2 • La herramienta en uso

Cargar → seleccionar → ejecutar → descargar → interpretar

El flujo completo, en cinco pasos

- 1** **Cargar el PRODOC** un único archivo .docx por evaluación
- 2** **Seleccionar el alcance** rúbrica completa, una sección o subsecciones concretas
- 3** **Ejecutar** el Agente lanza el trabajo y consulta su avance hasta terminar
- 4** **Descargar el Excel** es el registro auditable de la evaluación
- 5** **Interpretar** localizar evidencia y priorizar los criterios marcados

Indique el alcance en el mismo mensaje en que sube el archivo: ahorra una ronda de preguntas y acota el costo desde el inicio.

Pasos 1 y 2 • Cargar y acotar

- **Abra el Agente y salude.** Se presenta solo: explica qué evalúa, qué secciones existen y qué puede filtrar. Eso no consume una evaluación.
- **Adjunte un solo .docx.** Si sube varios, el Agente le pedirá elegir uno: la evaluación es de un documento por vez.
- **Diga qué quiere evaluar.** Ejemplos de instrucción:
 - «Evalúa este PRODOC con la rúbrica completa»
 - «Evalúa solo la sección 3 (Marco de resultados) y resume las brechas»
 - «Evalúa solo 1.1 y 2.3»

Recomendación para empezar: una sección primero. Llega antes, cuesta menos y permite calibrar la lectura antes de una corrida completa.

Paso 3 · Qué ocurre mientras se ejecuta

- 1** El Agente descarga el documento y extrae su texto por secciones
- 2** Carga la rúbrica del servidor y filtra los criterios que usted pidió
- 3** Lanza las evaluaciones en paralelo cada criterio, 10 veces, hasta 48 consultas simultáneas
- 4** Consolida cada criterio resultado modal + porcentaje de estabilidad
- 5** Construye el Excel y lo adjunta a la conversación

No hay que preguntar «¿ya terminó?»: el Agente informa el avance solo — «180/760 (24%), quedan unos 3 minutos» — hasta entregar el archivo.

Paso 4 • El Excel: hoja «Resultado Diagnostico»

Una sola hoja, con una fila por criterio evaluado. Es el registro auditable: consérvelo.

Grupo de columnas	Qué contiene	Para qué sirve
Identificación	ID • Subsección • Criterio • Transversales	Ubicar el criterio en el Checklist
Resultado	Respuesta (Yes / Partial / No / Not Found / N/A)	El diagnóstico del criterio
Confianza	Estabilidad (%) • Estable ($\geq 80\%$) • Resultado Alternativo	Cuánto coincidieron las 10 corridas
Sustento	Razonamiento (chequeo por chequeo) • Evidencia citada	Verificar por qué llegó a ese resultado
Prioridad	Revisión humana recomendada	Su cola de trabajo

«Not Found» no es «No». «No» afirma que el criterio no se cumple; «Not Found» afirma que el documento no permite determinarlo. La acción es distinta.

Cómo leer una fila, en orden

1

Mire la Respuesta Yes / Partial / No / Not Found / N/A

2

Mire la Estabilidad ¿coincidieron las 10 corridas o hubo desacuerdo?

3

Lea la Evidencia citada ¿ese pasaje realmente sostiene el resultado?

4

Lea el Razonamiento qué chequeo falló y con qué justificación

5

Decida ¿brecha de diseño, brecha documental, o error del Agente?

Nunca acepte una respuesta sin abrir la evidencia. La evidencia es lo que convierte un resultado automático en un diagnóstico defendible.

Qué contiene la columna Razonamiento

POR QUÉ PARTIAL · Se cumplen 2 de 3 chequeos.

Falta: articular cómo el proyecto cuestiona normas de poder.

VERIFICACIÓN

✓ ¿Distingue el tipo de enfoque?

la sección 3.2 distingue los tres enfoques.

✗ ¿Articula cómo cuestiona normas de poder?

no se explica el mecanismo en ninguna sección.

✓ ¿Acciones dedicadas a transformar relaciones?

actividad 2.4, con presupuesto asignado.

ESTABILIDAD · 6 de 10 corridas coincidieron. Alternativo: No.

REGLA · se requieren los 3 chequeos ($T1 \wedge T2 \wedge T3$)

POR QUÉ

el motivo, en una línea. Si va con prisa, lea solo esto.

VERIFICACIÓN

cada chequeo enunciado completo, con ✓ / ✗ y su justificación.

ESTABILIDAD

cuántas de las 10 corridas coincidieron.

REGLA

la regla formal del Checklist, para auditoría.

Ya no hay que descifrar « $T1 \wedge T2 \wedge T3$ »: cada chequeo se lee solo. La regla formal sigue abajo, para quien necesite trazar el resultado.

Paso 5 • Localizar la evidencia en el PRODOC

- **La columna Evidencia trae la cita textual** que el Agente usó. Búsquela en el PRODOC con Ctrl+F para verla en su contexto.
- **Cuando la evidencia es una ausencia**, el Agente lo dice explícitamente: «No se encontró sección X». Eso también es un hallazgo verificable.
- **Tres desenlaces posibles al verificar:**

La información sí está y el Agente no la reconoció → se descarta el diagnóstico automático

La información no está pero el formulador la conoce → mejorar el PRODOC

La información no existe aún → resolver antes de cerrar la formulación, o trasladar a inception

La fórmula: ¿existe? → ¿es suficiente? → ¿está documentado?

Vinculación con otros recursos

Recurso	Qué aporta	Ejemplo de uso
Chatea con el Agente	Preguntar sobre el resultado ya generado, en lenguaje natural	«Resume las brechas de la sección 3 en tres puntos»
Otros GPTs desarrollados	Atributos Específicos (género, participación, transición justa) y Sostenibilidad	Profundizar un tema que el Checklist solo toca de forma transversal
Chatbot i-EVal	Evidencia de evaluaciones anteriores en la región	«¿Qué problemas recurrentes han identificado las evaluaciones en proyectos con ministerios de trabajo?»

El Excel no es el final del proceso: es el punto de partida de la conversación con el equipo formulador.

Preguntas frecuentes

Pregunta	Respuesta breve
¿Por qué puede cambiar una respuesta?	El modelo no es determinista. Por eso repetimos 10 veces y reportamos estabilidad.
¿Qué significa una estabilidad de 50–70%?	Las corridas no coincidieron: criterio ambiguo o evidencia insuficiente. Revisión humana.
¿Por qué no encontró algo que yo sé que existe?	Solo lee el documento. Si está y no lo vio, verifíquelo y descarte el diagnóstico.
¿Por qué no me da recomendaciones de mejora?	No incorpora conocimiento externo al documento. Las recomendaciones salen de su lectura.
¿Cuánto cuesta evaluar un PRODOC?	Depende del tamaño del documento y de cuántos criterios se evalúen. Filtrar reduce el costo.
¿Puedo evaluar otros documentos?	Para género, participación, transición justa y sostenibilidad existen agentes específicos.

Qué recordar de este bloque

- **El Agente lee el documento, no el proyecto.** Un «No» puede ser una brecha de diseño o simplemente algo no documentado. Distinguirlo es trabajo suyo.
- **Repite 10 veces y le dice cuánto coincidió.** La estabilidad es una medida de confianza interna, no de acierto.
- **Todo resultado viene con su evidencia.** Verifíquela siempre: es lo que hace el diagnóstico defendible ante el equipo formulador.
- **La columna «Revisión humana recomendada» es su cola de trabajo.** Empiece por ahí.

El valor de la herramienta depende de la calidad de la revisión humana posterior.

Preguntas

Agente GPT · Appraisal Checklist de PRODOCs · Ahmed Eid